

Limitaciones para CSVs propios

1. Solo columnas numéricas como features

El use case hace `select_dtypes(include=[np.number])` antes de entrenar. Cualquier columna de texto ("alto", "masculino", "Lima") es silenciosamente descartada. Si todas las features son texto, el entrenamiento falla con un error de "no hay columnas numéricas".

2. Variable objetivo debe ser categórica con al menos 2 clases

Solo soporta clasificación binaria o multiclase. No soporta regresión (variable objetivo continua como una nota del 0 al 20).

3. Sin encoding automático

Variables categóricas codificadas como texto ("Bajo", "Medio", "Alto") no se procesan. El usuario tendría que pre-codificarlas manualmente (ej. 1, 2, 3) antes de subir el CSV.

4. Sin manejo de valores faltantes avanzado

Solo se eliminan filas con NaN (dropna implícito via `notna()`). Si el dataset tiene muchos nulos, puede quedar con muy pocas muestras sin aviso claro al usuario.

5. Sin detección de separadores

`pd.read_csv()` asume separador `,`. CSVs europeos con `;` o separados por tabulaciones fallarán con un parse incorrecto o generarán una sola columna.

6. Sin validación de tamaño mínimo

No hay un mínimo de filas requerido por clase para garantizar que `train_test_split` funcione correctamente. Datasets muy pequeños (menos de ~20 filas) pueden fallar incluso con el manejo de stratify actual.

7. Sin normalización de nombres de columnas

Espacios o caracteres especiales en nombres de columnas ("horas estudio", "nota_final?") pueden causar comportamientos inesperados al construir el `pd.DataFrame` de predicción.